

Языковая сложность в мультязыковых моделях



Репозиторий с
презентацией

Капелюшников Андрей

1 курс магистратуры МФТИ
Кафедра управления
технологическими проектами

Постановка задачи

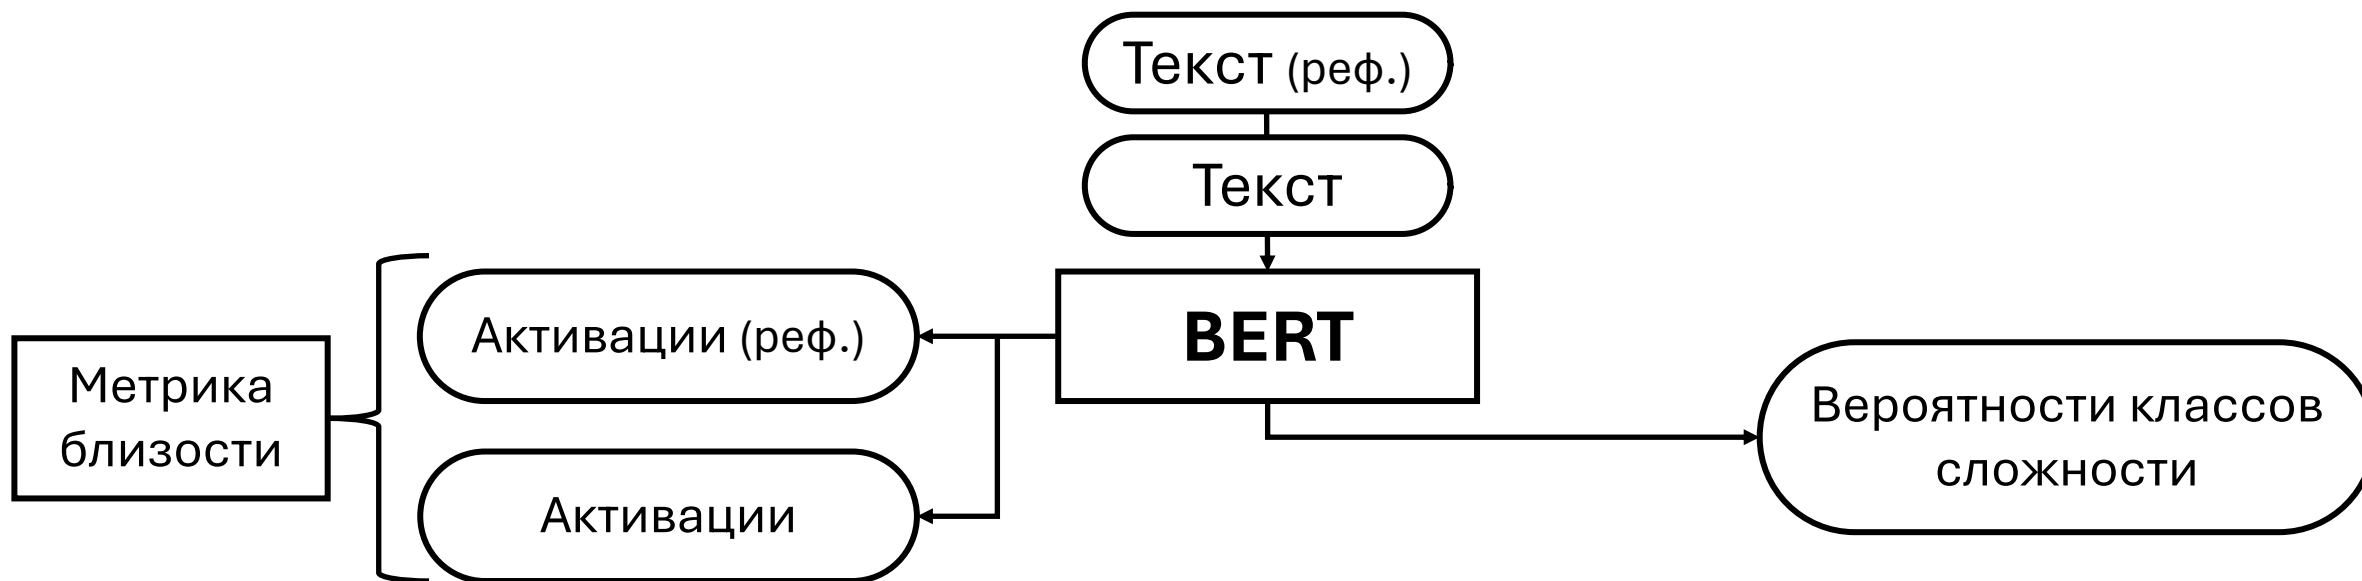
Основная задача

Изучить поведение скрытого пространства BERT при переносе обучения между языками

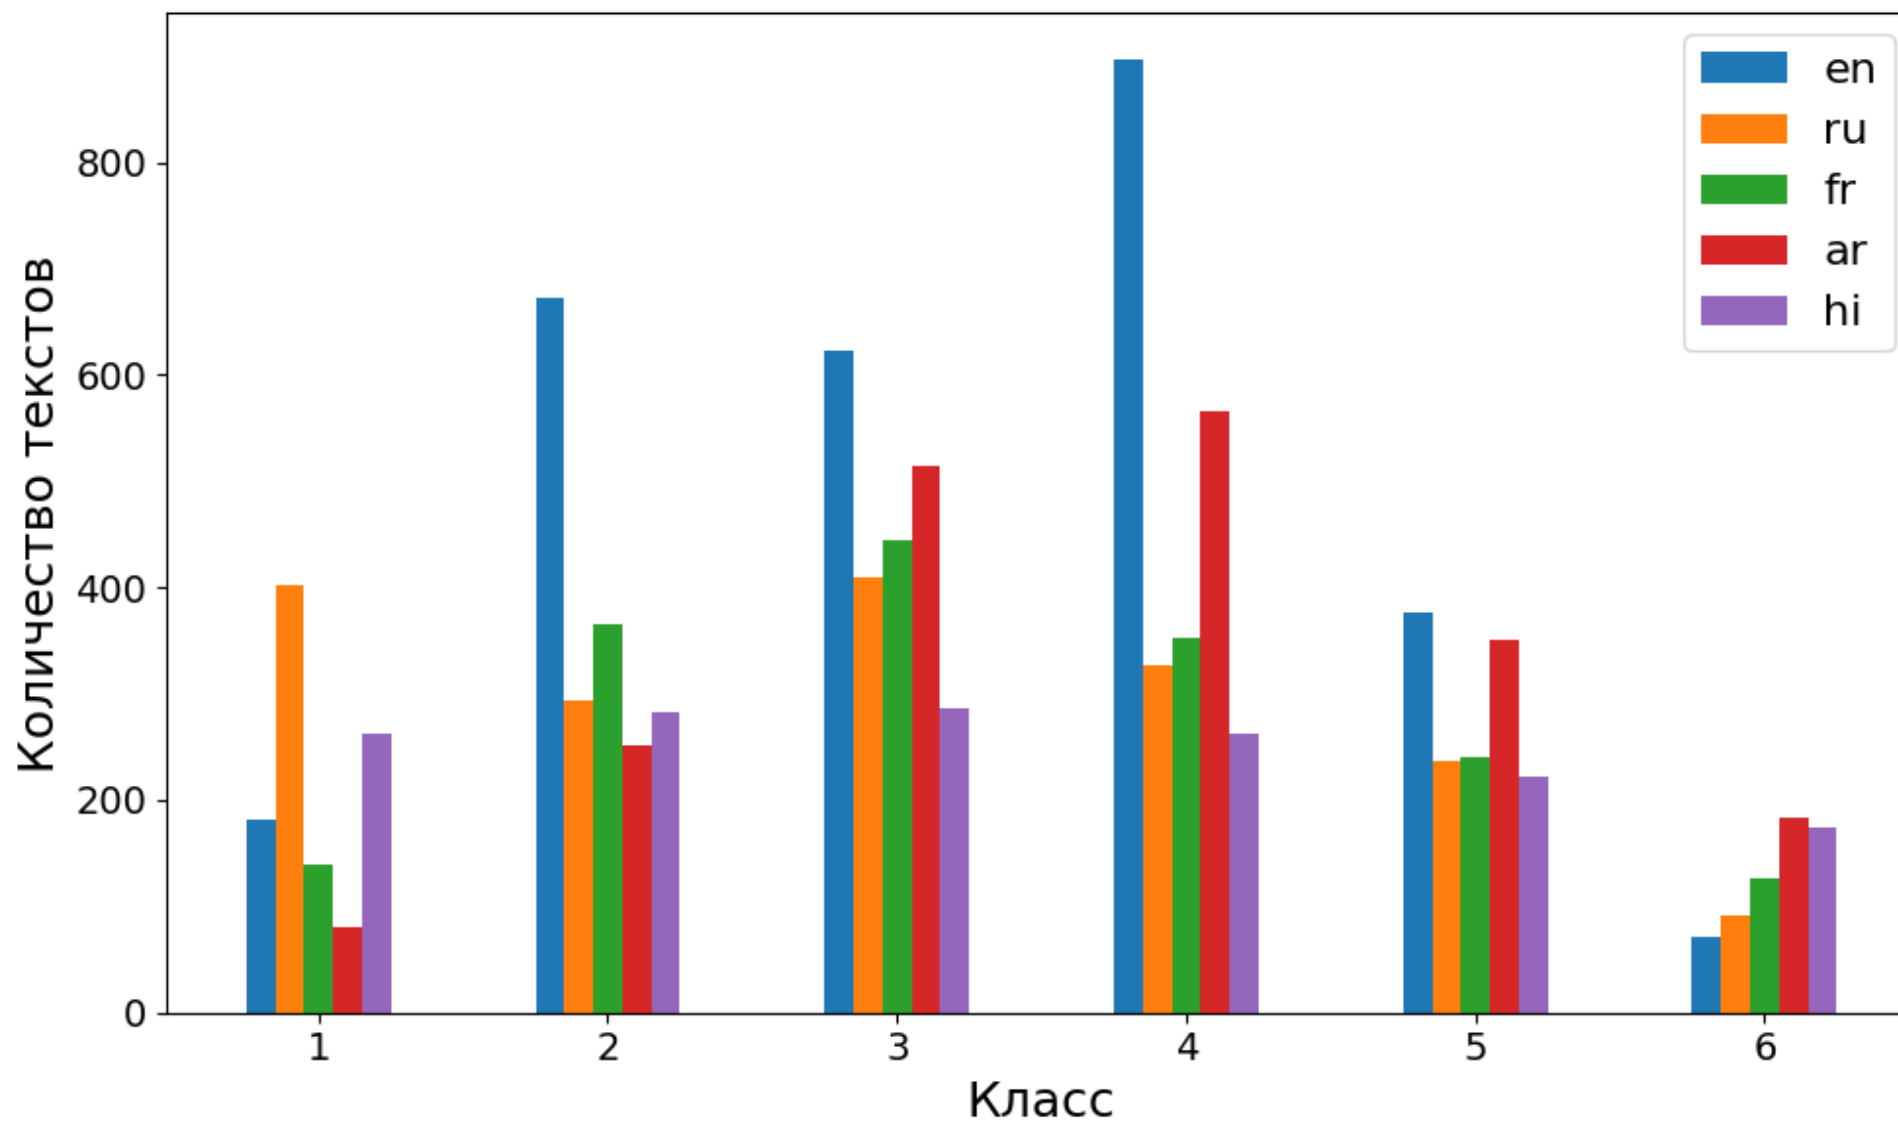
Задача определение языковой сложности

Разделить тексты на не менее, чем 2 класса по сложности их восприятия

Цель: Найти метрику (метрики), корректно отражающие процессы в скрытых пространствах BERT в задаче языкового переноса



ReadMe++



Vikidia vs Wikipedia

Название	Vikidia	Wikipedia
Love	Symbol of love. Love is when you like someone, very intensely. There are different types of love relationships: the relationships between a boyfriend and girlfriend couple (love relation), the relations between parents and children, and between brothers and sisters.	Love encompasses a range of strong and positive emotional and mental states, from the most sublime virtue or good habit, the deepest interpersonal affection, to the simplest pleasure.
Любовь	Символ любви. Любовь – это когда тебе кто-то очень сильно нравится. Существуют разные виды любовных отношений: отношения между парой и девушкой (любовные отношения), отношения между родителями и детьми, между братьями и сестрами.	Любовь охватывает целый ряд сильных и позитивных эмоциональных и психических состояний: от самой возвышенной добродетели или хорошей привычки, глубочайшей межличностной привязанности до простейшего удовольствия.
City	A city is a place where many people live. There is no simple definition of how big a city can be. Some very large cities, such as Tokyo (Japan) and Mexico City (Mexico), have tens of millions of people.	A city is a human settlement of a notable size. The term "city" has different meanings around the world and in some places the settlement can be very small.
Город	Город – это место, где живет много людей. Не существует простого определения того, насколько большим может быть город. В некоторых очень крупных городах, таких как Токио (Япония) и Мехико (Мексика), проживают десятки миллионов человек.	Город – это поселение людей значительных размеров. Термин «город» имеет разные значения по всему миру, и в некоторых местах поселение может быть очень маленьким. Даже если этот термин ограничен более крупными населенными пунктами.

Перенос

Язык обучения модели – английский

f1 (macro)	XNLI [2] (3 класса)	ReadMe++ (6 классов)	Vikidia vs Wikipedia (2 класса)
en	0.69	0.52	0.87
ru	0.55	0.44	0.72
fr	0.60	0.46	0.77
hi	0.45	0.34	0.61
ar	0.51	0.41	0.77

ANC [2]

функция **ANC** (Слой_1, Слой_2) :

X = Слой_1 - сред(Слой_1, ось=0)







Y = Слой_2 - сред(Слой_2, ось=0)

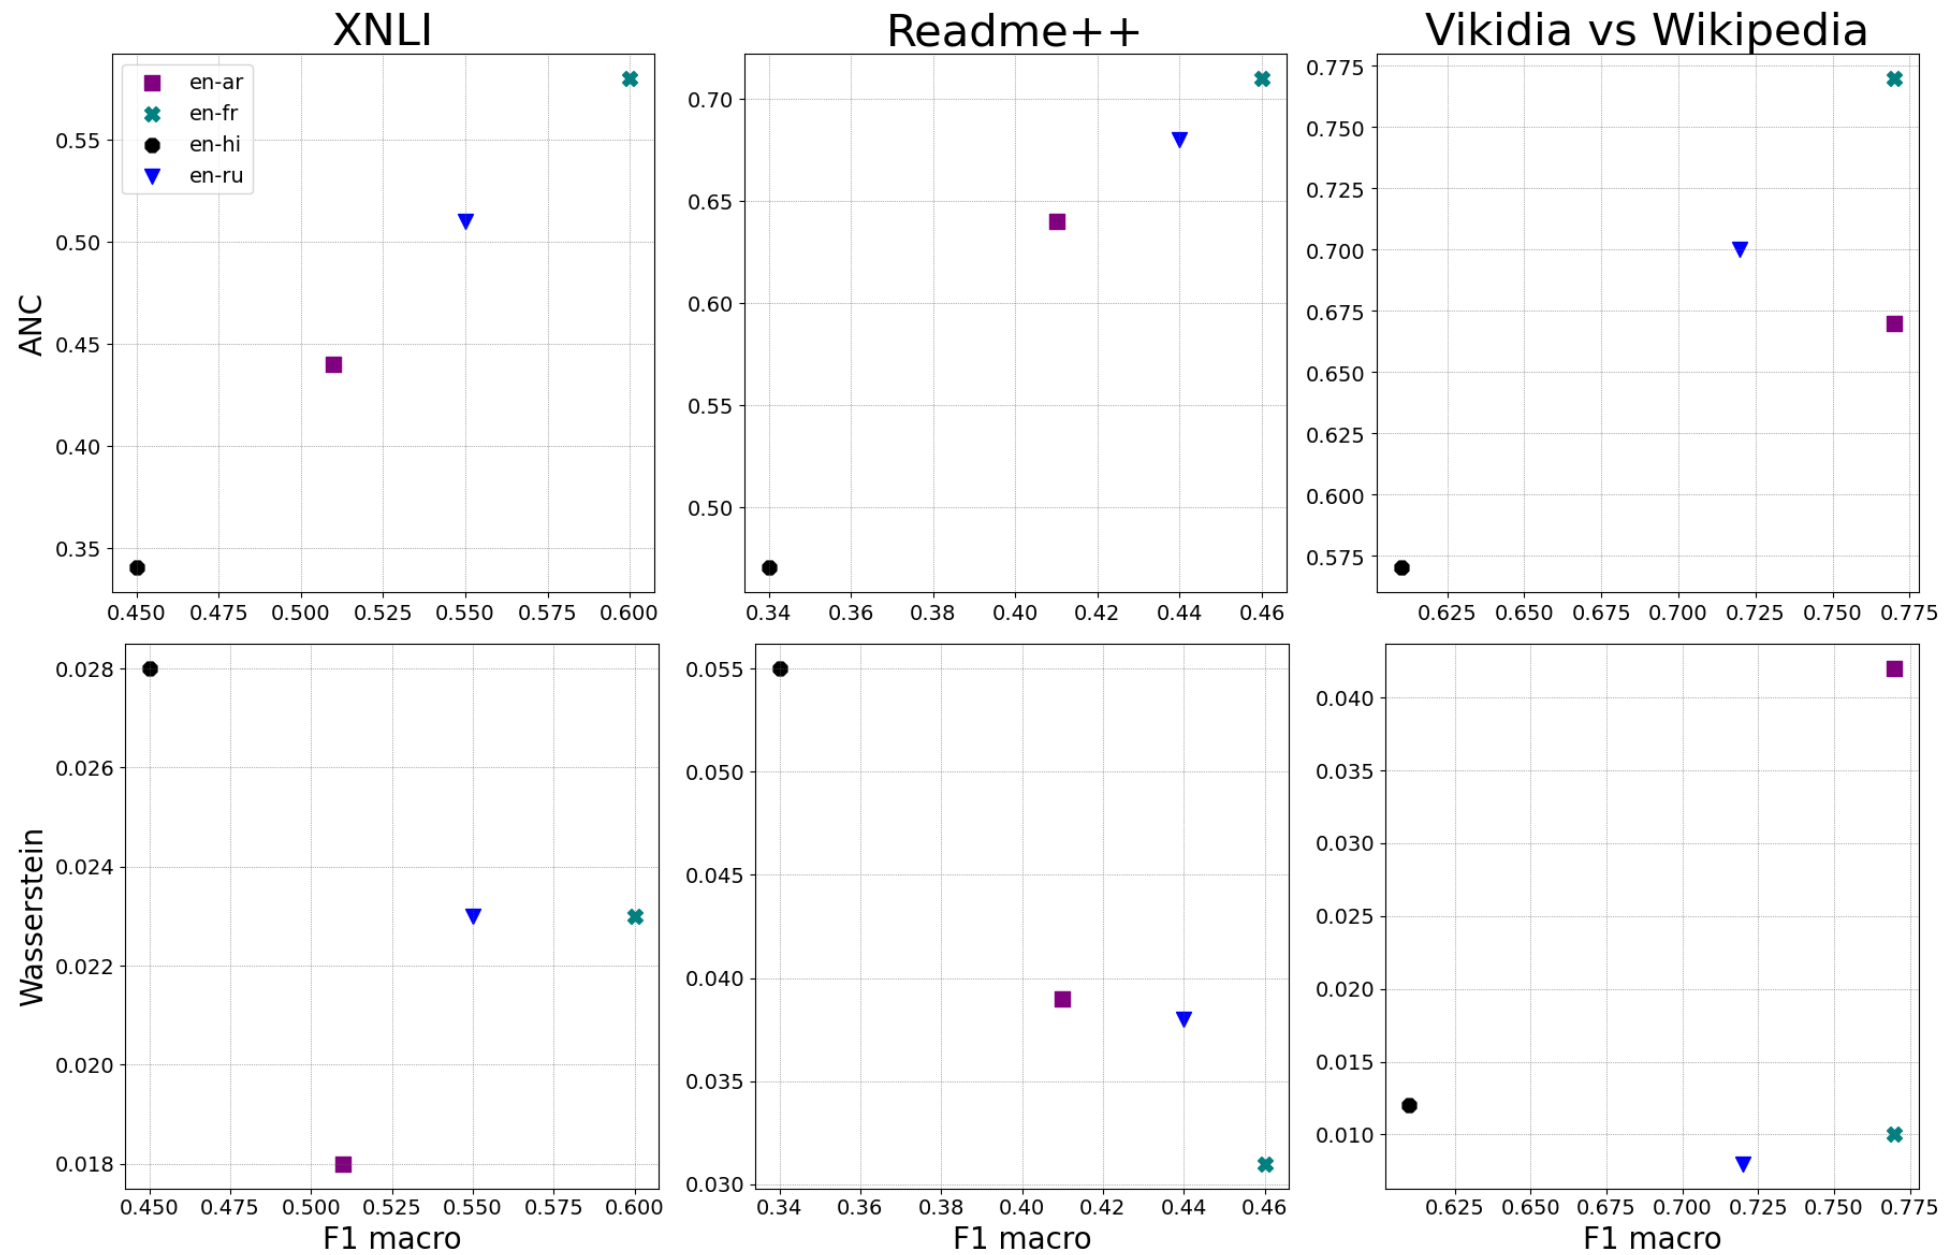
ANC = 0

цикл i (0, длина(X, ось=0)) :

$$\text{ANC} += \left| \frac{X[i] \cdot Y[i]}{\|X[i]\| \|Y[i]\|} \right|$$


вернуть ANC / длина(X, ось=0)





Выводы


1. На задачах XNLI и языковой сложности на ReadMe++ метрика ANC убывает в ряду языков французский, русский, арабский, хинди
2. Метрика ANC и расстояние Вассерштайна дают представление о процессах, происходящих на слоях BERT
3. До 7 слоя BERT вектора «выравниваются», затем затем изменяется распределение координат без изменения направления векторов
4. Метрика ANC коррелирует с качеством переноса обучения модели



Репозиторий с
презентацией

Капелюшников Андрей

ТГ: @andreykapelushnikov



Код
экспериментов

Литература

1. Naous T. [et al.]. ReadMe++: Benchmarking Multilingual Language Models for Multi-Domain Readability Assessment // arXiv preprint arXiv:2305.14463. 2023.
2. Maksym D., Mark F., Cross-lingual Similarity of Multilingual Representations Revisited // Association for Computational Linguistics. 2022. V. 1. P. 185–195.


Дополнительно

ReadMe++

Предложение	Класс
Поставьте тостер на ровную и жаропрочную поверхность.	1
They took over China, Persia, Turkestan, and Russia.	1
В целом ретиноиды повышают чувствительность кожи к солнечному свету, поэтому их рекомендуется использовать в ночное время.	2
A large share of citrus fruit in the US is grown in Florida and California.	2
Его интересовала экономическая динамика капитализма, объяснение которой учёный находил в инновациях.	3
Thus two people can view the same event and come away with entirely different perceptions of it, even disagreeing about simple facts.	3
Египетскими мастерами создавались прекрасные настенные росписи и статуи, были освоены способы производства стекла и фаянса, поэтами и писателями созданы новые формы в литературе.	4
It can be proven to be equivalent to absolute convergence.	4
К концу 1-х суток начиналось их снижение, которое достигало к окончанию инкубационного периода (3-4-е сутки после инфицирования) исходного уровня и затем снижалось до 0 за 2-3 сут до летального исхода.	5
In the UK, transmission costs are about 0.2 p per kWh compared to a delivered domestic price of around 10 p per kWh. Research evaluates the level of capital expenditure in the electric power T&D equipment market will be worth \$128.9 bn in 2011.	5
И на суше и водах, веслом и посохом, будут песнь и молитва бездны пасти, и осядет прахом взметенное порохом, и домой вернется пропавший без вести.	6
Eukaryotic cells also have cytoskeleton that is made up of microtubules, intermediate filaments, and microfilaments, all of which provide support for the cell and are involved in the movement of the cell and its organelles.	6

ReadMe++

Модель: en, Выборка: ru, f1 macro: 0.44




Модель: en, Выборка: hi, f1 macro: 0.34



Модель: en, Выборка: en, f1 macro: 0.52








Модель: en, Выборка: fr, f1 macro: 0.46








Модель: en, Выборка: ar, f1 macro: 0.41





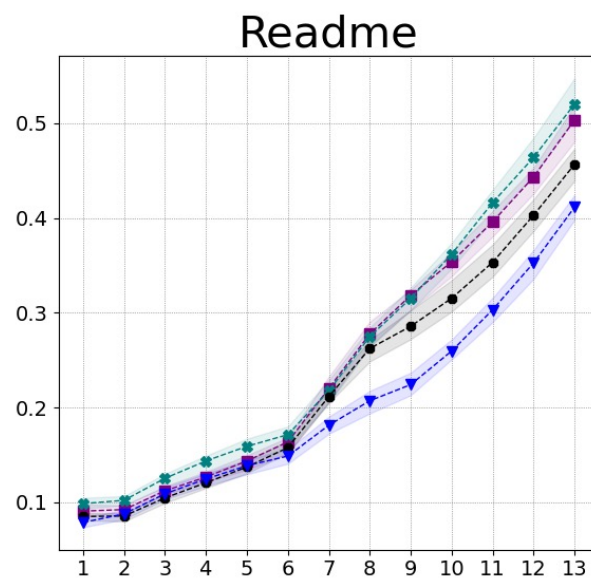
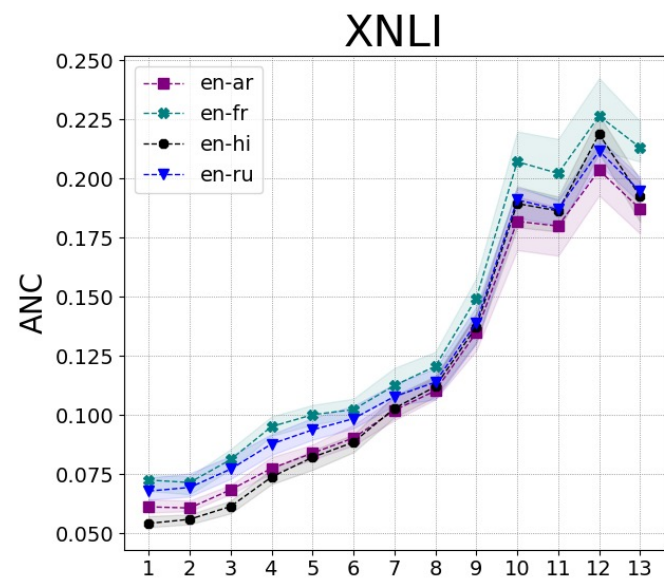


Vikidia vs Wikipedia



XNLI





Слой

Слой

Слой